

基于改进 YOLOv11 的风电叶片缺陷检测系统

课程设计报告

2026 年 5 月 24 日

摘要

风力发电作为清洁能源的重要组成部分，其关键部件——风电叶片的缺陷检测对保障机组安全运行至关重要。传统人工检测方法效率低、主观性强，难以满足大规模风电场的巡检需求。本文基于 YOLO 系列目标检测模型，针对风电叶片表面缺陷（裂纹、腐蚀）进行自动检测研究。

首先，构建了包含 1,096 张图像的风电叶片缺陷检测数据集（裂纹和腐蚀两类缺陷），采用 YOLO 格式标注。其次，以 YOLOv11n 为基线模型，从 COCO 预训练权重微调，基线 mAP@0.5 达到 78.01%。然后，设计了系统性的对比实验，在相同条件下比较 YOLOv5n、YOLOv8n 和 YOLOv11n 的检测性能。最后，通过冻结策略消融实验，验证不同冻结层数对小数据集迁移学习效果的影响。

实验结果表明：YOLOv8n 在该数据集上表现最优，mAP@0.5 达到 82.80%，比基线提升 4.79 个百分点；全量微调（freeze=0）的 YOLOv11n（80.35%）优于冻结策略，说明 COCO 预训练权重对小数据集检测任务至关重要。本研究为风电叶片缺陷检测提供了轻量级、高精度的解决方案。

关键词：风电叶片；缺陷检测；YOLOv11；迁移学习；冻结策略

目录

1	绪论	3
1.1	研究背景与意义	3
1.2	国内外研究现状	3
1.2.1	传统图像处理方法	3
1.2.2	深度学习目标检测方法	3
1.2.3	注意力机制与特征融合	4
1.3	本文主要工作	4
2	相关技术	4
2.1	YOLO 目标检测框架	4
2.2	注意力机制	5
2.2.1	通道注意力	5
2.2.2	空间注意力	5
2.2.3	坐标注意力 (CA)	5
2.2.4	PSA 机制	5
2.3	特征融合技术	5
2.4	轻量化技术	6
3	方法设计	6
3.1	数据集与预处理	6
3.1.1	数据来源	6
3.1.2	缺陷类别	6
3.1.3	数据规模	6
3.1.4	数据格式	6
3.1.5	数据增强	6
3.2	基线模型选择	7
3.3	对比实验设计	7
3.4	消融实验设计——冻结策略	7
3.5	迁移学习策略	8
4	实验与分析	8
4.1	实验环境	8
4.2	评估指标	8
4.3	训练策略	9
4.4	模型对比实验	9
4.5	消融实验——冻结策略	10

4.6	结果分析	11
4.6.1	参数量与精度权衡	11
4.6.2	训练曲线分析	11
4.6.3	迁移学习的重要性	11
5	总结与展望	11
5.1	工作总结	11
5.2	主要发现	11
5.3	不足与展望	12
	参考文献	12
A	完整训练配置	14
B	模型结构详细说明	14

1 绪论

1.1 研究背景与意义

风力发电是全球能源转型的重要支柱。截至 2025 年，全球风电装机容量已超过 1,000 GW，中国作为全球最大的风电市场，装机规模持续扩大。风电叶片作为风力发电机组的核心部件，长期暴露在复杂自然环境中，容易产生裂纹、腐蚀、雷击损伤等表面缺陷。这些缺陷如果不能及时检测和修复，可能导致叶片断裂等严重事故，造成巨大的经济损失和安全风险。

传统的风电叶片检测主要依赖人工目视检查，存在以下问题：

- **效率低下：**单台风机叶片检查需要数小时，大型风电场数百台机组的全面巡检周期长达数月；
- **主观性强：**检测结果依赖检查人员的经验和判断，漏检率和误检率较高；
- **安全风险：**高空作业存在安全隐患，恶劣天气条件下无法进行检查；
- **成本高昂：**需要专业检测人员和大型设备，运维成本居高不下。

因此，开发自动化、智能化的风电叶片缺陷检测系统具有重要的工程应用价值。深度学习目标检测技术的发展为这一问题提供了新的解决思路。

1.2 国内外研究现状

1.2.1 传统图像处理方法

早期的缺陷检测研究主要基于传统图像处理技术，包括边缘检测（Canny、Sobel）、形态学运算、阈值分割等方法。这些方法对简单缺陷有效，但面对复杂背景和多变光照条件时鲁棒性不足。

1.2.2 深度学习目标检测方法

近年来，基于深度学习的目标检测方法在工业缺陷检测领域取得了显著进展。主要分为两类：

两阶段方法：以 Faster R-CNN 为代表，先生成候选区域再进行分类和定位，精度较高但速度较慢。

单阶段方法：以 YOLO（You Only Look Once）系列为代表，将检测任务视为回归问题，直接从图像像素预测边界框和类别概率，在速度和精度之间取得了良好平衡。YOLO 系列从 v1 到 v11 不断演进，在网络结构、特征提取、多尺度检测等方面持续改进。

1.2.3 注意力机制与特征融合

注意力机制（如 SE、CBAM、CA）通过自适应加权增强重要特征，在缺陷检测中得到广泛应用。特征融合技术（FPN、PANet、BiFPN）通过多尺度特征聚合提升小目标检测能力。

1.3 本文主要工作

本文的主要贡献包括：

1. 构建了风电叶片缺陷检测数据集，包含 1,096 张图像，涵盖裂纹（crack）和腐蚀（erosion）两类缺陷；
2. 以 YOLOv11n 为基线模型，从 COCO 预训练权重微调，建立了基线性能指标（ $mAP@0.5 = 78.01\%$ ）；
3. 设计了系统性对比实验，在统一条件下比较 YOLOv5n、YOLOv8n 和 YOLOv11n 的检测性能；
4. 通过冻结策略消融实验（freeze=0/5/10/11），验证了不同迁移学习策略对小数据集检测性能的影响；
5. 关键发现：YOLOv8n 在小数据集上表现最优（ $mAP@0.5 = 82.80\%$ ），COCO 预训练权重对小数据集检测至关重要。

2 相关技术

2.1 YOLO 目标检测框架

YOLO（You Only Look Once）系列是当前最流行的单阶段目标检测算法。其核心思想是将目标检测任务转化为端到端的回归问题，通过单次前向传播同时预测边界框位置和类别概率。

YOLO 模型通常由三部分组成：

- **Backbone**（骨干网络）：负责从输入图像中提取多层次特征，如 CSPDarknet53、C2f 模块等；
- **Neck**（颈部网络）：负责多尺度特征融合，如 PANet、BiFPN 等；
- **Head**（检测头）：负责最终的边界框回归和分类预测。

本文涉及的 YOLO 版本包括：

- **YOLOv5n**：采用 CSPDarknet53 Backbone + PANet Neck，参数量 2.50M，计算量 7.1 GFLOPs；
- **YOLOv8n**：改进 Backbone + C2f 模块 + PANet Neck，参数量 3.01M，计算量 8.1 GFLOPs；

- **YOLOv11n**: 采用 C3k2 + C2PSA 注意力 + SPPF, 参数量 2.62M, 计算量 6.3 GFLOPs。

2.2 注意力机制

注意力机制通过自适应加权机制增强网络对重要特征的关注能力, 在缺陷检测中发挥重要作用。

2.2.1 通道注意力

SE (Squeeze-and-Excitation) 模块通过全局平均池化获取通道统计信息, 再通过两层全连接网络生成通道注意力权重, 自适应调整各通道特征的重要性。

2.2.2 空间注意力

空间注意力机制关注图像中不同空间位置的重要性, 通常通过卷积操作生成空间注意力图, 增强目标区域的特征响应。

2.2.3 坐标注意力 (CA)

坐标注意力 (Coordinate Attention) 将通道注意力分解为两个一维特征编码, 分别捕获水平和垂直方向的位置信息, 同时保留精确的位置感知能力。

2.2.4 PSA 机制

PSA (Pixel Shift Attention) 是 YOLOv11 引入的注意力机制, 通过像素移位操作在局部窗口内建模像素间关系, 增强特征的局部表达能力。本文在 YOLOv11n 中使用 C2PSA 模块, 其 repeat 参数从默认 2 增加到 4 以增强注意力效果。

2.3 特征融合技术

多尺度特征融合是提升目标检测性能的关键技术, 主要方法包括:

- **FPN** (Feature Pyramid Network): 自顶向下的特征金字塔, 将高层语义特征传递到低层;
- **PANet** (Path Aggregation Network): 在 FPN 基础上增加自底向上的路径聚合, 增强特征传播;
- **BiFPN** (Bidirectional Feature Pyramid Network): 双向特征金字塔, 支持更高效的多尺度特征融合。

2.4 轻量化技术

针对边缘部署需求，轻量化技术通过减少模型参数量和计算量实现高效推理：

- 深度可分离卷积：将标准卷积分解为逐深度和逐点卷积，减少参数量；
- GhostNet/GSConv：使用轻量级特征生成模块替代标准卷积；
- 减少网络深度：如将 C3k2 模块的 repeat 参数从 2 减至 1。

3 方法设计

3.1 数据集与预处理

3.1.1 数据来源

数据集来源于风电叶片实际巡检图像，涵盖正常叶片和含有缺陷的叶片图像。

3.1.2 缺陷类别

数据集包含两类缺陷：

- 裂纹 (crack)：叶片表面的线性裂缝，可能由疲劳载荷或制造缺陷引起；
- 腐蚀 (erosion)：叶片表面的材料退化，通常由环境因素（如雨水、盐雾）导致。

3.1.3 数据规模

数据集共 1,096 张图像，按 7:1.5:1.5 比例划分：

- 训练集：764 张图像
- 验证集：166 张图像
- 测试集：166 张图像

3.1.4 数据格式

采用 YOLO 格式标注，每张图像对应一个 txt 标注文件，包含类别 ID 和归一化的边界框坐标 (x_{center} , y_{center} , $width$, $height$)。

3.1.5 数据增强

训练过程中采用多种数据增强策略：

- Mosaic 增强 ($m = 1.0$)：将 4 张图像拼接为一张，丰富目标尺度和背景；
- MixUp 增强 ($m = 0.1$)：随机混合两张图像，增强模型鲁棒性；
- CopyPaste 增强 ($m = 0.1$)：复制粘贴目标区域，增加正样本数量。

3.2 基线模型选择

选择 YOLOv11n 作为基线模型，原因如下：

- 参数量仅 2.62M，计算量 6.3 GFLOPs，适合资源受限环境部署；
- 引入 C2PSA 注意力机制，在保持轻量化的同时增强特征表达能力；
- 作为 YOLO 系列最新版本，代表了当前单阶段检测器的技术水平。

基线训练从 COCO 预训练权重 yolo11n.pt 微调，基线性能为 $mAP@0.5 = 78.01\%$ 。

3.3 对比实验设计

对比三种主流 YOLO 轻量级模型在同一数据集上的检测性能：

表 1: 对比实验模型配置

模型	Backbone	Neck	参数量
YOLOv5n	CSPDarknet53	PANet	2.50M
YOLOv8n	C2f-Backbone	PANet	3.01M
YOLOv11n	C3k2+C2PSA	PANet	2.62M

所有模型均从 COCO 预训练权重微调，采用统一的训练配置：

- 训练轮次：150 epochs，批次大小：8，图像尺寸：640×640
- 优化器：AdamW（自动选择），初始学习率：0.001
- 学习率调度：余弦退火衰减（ $lr_0=0.001 \rightarrow lr_f=0.0001$ ）
- 预热策略：5 个 epoch，预热动量 0.8
- 早停机制：patience=30

3.4 消融实验设计——冻结策略

在 YOLOv11n 上对比不同冻结层数的迁移学习效果，验证冻结策略对小数据集检测性能的影响：

- **freeze=0**：无冻结，全量微调（从 COCO 预训练开始）
- **freeze=5**：冻结前 5 层（Backbone 前半部分）
- **freeze=10**：冻结前 10 层（几乎全部 Backbone）
- **freeze=11**：冻结全部 Backbone，仅训练 Head

目的：验证在小规模数据集上，冻结策略对检测性能和收敛速度的影响。

3.5 迁移学习策略

核心发现：从 YAML 构建的模型随机初始化训练效果极差（mAP50 仅 0.43–0.57），说明小数据集（764 张训练图像）不足以从头训练有效的检测模型。

解决方案：采用迁移学习策略，从 COCO 预训练权重或基线 best.pt 加载权重进行微调。

微调策略包括：

- 余弦退火学习率衰减：lr0=0.001 → lrf=0.0001
- Warmup 预热：前 5 个 epoch 逐步增加学习率
- 早停机制：patience=30，避免过拟合

4 实验与分析

4.1 实验环境

表 2: 实验环境配置

项目	配置
GPU	NVIDIA RTX 4060 Laptop (8GB VRAM)
CUDA	13.0
PyTorch	2.6.0
ultralytics	8.4.48
Python	3.9
操作系统	Windows 11

4.2 评估指标

采用以下指标评估检测性能：

- **mAP@0.5**：IoU=0.5 时的平均精度均值，主要评价指标；
- **mAP@0.5:0.95**：多 IoU 阈值下的平均精度均值，更严格的评价标准；
- **Precision**（精确率）：检测结果中正确检测的比例；
- **Recall**（召回率）：所有真实目标中被正确检测的比例。

此外，还统计了模型的参数量（Params）和计算量（GFLOPs）。

4.3 训练策略

统一训练配置如下：

表 3: 统一训练超参数

参数	值
epochs	150
batch	8
imgsz	640×640
optimizer	auto (AdamW)
lr0 / lrf	0.001 / 0.0001
cos_lr	True
warmup_epochs	5
weight_decay	0.0005
patience	30
Mosaic	1.0
MixUp	0.1
CopyPaste	0.1

4.4 模型对比实验

对比不同 YOLO 版本在同一风电叶片缺陷数据集上的检测性能。

表 4: 模型对比实验结果

模型	mAP@0.5	mAP@0.5:0.95	Precision	Recall	Params
YOLOv11n (Baseline)	0.7801	0.4767	0.8337	0.6769	2.62M
YOLOv5n	0.8078	0.4887	0.8581	0.7000	2.50M
YOLOv8n	0.8280	0.5218	0.9024	0.7237	3.01M
YOLOv11n+Freeze	0.7644	0.4629	0.8488	0.6667	2.62M

分析：

1. **YOLOv8n 表现最优：** mAP@0.5 达到 82.80%，比基线提升 4.79 个百分点，精确率达到 90.24%。YOLOv8n 的 C2f 模块在特征提取和表达方面具有优势，更适合小数据集的缺陷检测任务。

2. **YOLOv5n 优于基线**: 虽然参数量与 YOLOv11n 相当 (2.50M vs 2.62M), 但 mAP@0.5 更高 (80.78% vs 78.01%), 说明经典的 CSPDarknet53 在此数据集上的特征提取能力优于 YOLOv11 的改进 Backbone。
3. **YOLOv11n 注意力机制优势不明显**: C2PSA 注意力机制在小数据集 (764 张训练图像) 上未能充分发挥特征选择能力, 可能因数据量不足以训练有效的注意力权重。
4. **冻结 Backbone 降低性能**: YOLOv11n+Freeze(freeze=11) 的 mAP@0.5 为 76.44%, 低于全量训练基线 (78.01%), 但 Precision 有所提升 (84.88% vs 83.37%), 说明冻结策略减少了过拟合但也限制了模型的学习能力。

4.5 消融实验——冻结策略

在 YOLOv11n 上对比不同冻结层数的迁移学习效果。

表 5: 冻结策略消融实验结果

策略	冻结层数	mAP@0.5	vs 基线	Precision	Recall
无冻结	0	0.8035	+2.97%	0.8492	0.7232
部分冻结	5	0.6582	-15.63%	0.7689	0.5315
大部分冻结	10	0.7479	-4.13%	0.7669	0.6575
全冻结	11	0.7644	-2.02%	0.8488	0.6667

分析:

1. **全量微调效果最佳**: freeze=0 (无冻结) 的 mAP@0.5 为 80.35%, 比基线提升 2.97 个百分点。从 COCO 预训练权重开始, 以低学习率对所有层进行微调, 既能利用预训练特征又能充分适应目标数据集。
2. **freeze=5 效果最差**: mAP@0.5 仅为 65.82%, 远低于其他策略。冻结 Backbone 前 5 层 (早期低级特征层) 可能导致网络无法学习数据集特定的低级特征表示, 而仅微调后几层不足以弥补这一缺陷。
3. **freeze=10 和 freeze=11 表现中等**: 两者性能接近 (74.79% vs 76.44%), 冻结大部分 Backbone 后仅微调 Neck 和 Head 层, 模型容量受限但过拟合减少。
4. **非单调关系**: 冻结层数与检测性能之间并非简单的单调关系。freeze=5 的表现反而最差, 说明部分冻结可能造成特征提取和任务适配之间的不协调。

4.6 结果分析

4.6.1 参数量与精度权衡

YOLOv8n 以 3.01M 参数量取得最优性能 (82.80%)，而 YOLOv5n 以最少参数 (2.50M) 也达到 80.78%。YOLOv11n 虽然引入了 C2PSA 注意力机制，但在小数据集上并未带来显著性能提升。

4.6.2 训练曲线分析

所有模型在训练过程中均表现出良好的收敛趋势。YOLOv11n+Freeze 在约 30 个 epoch 即触发早停，表明冻结策略下模型快速收敛但容量受限。

4.6.3 迁移学习的重要性

实验表明，从 COCO 预训练权重微调是小数据集检测任务的关键。随机初始化训练（从 YAML 构建）的 mAP50 仅为 0.43–0.57，远低于迁移学习的结果。

5 总结与展望

5.1 工作总结

本文针对风电叶片缺陷检测问题，开展了以下工作：

1. 构建了风电叶片缺陷检测数据集，包含 1,096 张图像，涵盖裂纹和腐蚀两类缺陷；
2. 以 YOLOv11n 为基线模型，建立了 $\text{mAP}@0.5 = 78.01\%$ 的基线性能；
3. 设计了系统性对比实验，比较了 YOLOv5n、YOLOv8n 和 YOLOv11n 的检测性能；
4. 通过冻结策略消融实验，验证了不同迁移学习策略对检测性能的影响。

5.2 主要发现

1. **YOLOv8n 为最优模型：**在风电叶片缺陷检测任务上，YOLOv8n 的 $\text{mAP}@0.5$ 达到 82.80%，是所有对比模型中性能最高的。
2. **全量微调优于冻结策略：**从 COCO 预训练全量微调 (freeze=0) 的 YOLOv11n (80.35%) 优于所有冻结策略，说明低学习率全量微调是小数据集迁移学习的有效策略。
3. **冻结策略效果有限：**冻结 Backbone 的迁移学习策略 (freeze=11) 反而降低性能 (76.44%)，且 freeze=5 表现最差 (65.82%)，说明冻结策略在小数据集上限制了模型学习能力。

4. **COCO 预训练至关重要：**从 YAML 随机初始化训练的 mAP50 仅为 0.43–0.57，远低于迁移学习结果，证明预训练权重对小数据集检测任务不可或缺。
5. **YOLOv11 注意力机制在小数据集上优势有限：**C2PSA 注意力机制在 764 张训练图像上未能充分发挥作用，可能需要更大规模数据集才能体现其优势。

5.3 不足与展望

本研究存在以下不足，未来可从以下方向改进：

1. **数据量有限：**仅 764 张训练图像，可扩展更多缺陷类别和数据量，引入数据增强策略如旋转、翻转等；
2. **未探索更复杂的改进方案：**如 BiFPN 特征融合、GhostNet 轻量化、CA 注意力机制等网络结构改进；
3. **未考虑实时性优化：**如 TensorRT 导出、模型量化（INT8/FP16）、剪枝等部署优化技术；
4. **可引入更强的预训练模型：**如 YOLOv11s/m 等更大规模模型，或采用自监督预训练策略；
5. **可扩展到语义分割任务：**使用 YOLOv11-seg 实现像素级缺陷定位，提供更精确的缺陷边界信息。

参考文献

- [1] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779–788.
- [2] Jocher G, Chaurasia A, Qiu J. Ultralytics YOLOv8[J]. GitHub repository, 2023.
- [3] Li C, Li L, Geng Y, et al. YOLOv11: An improved real-time object detection algorithm[J]. arXiv preprint arXiv:2410.17725, 2024.
- [4] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 39(6): 1137–1149.
- [5] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2117–2125.
- [6] Liu S, Qi L, Qin H, et al. Path aggregation network for instance segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 8759–8768.

- [7] Tan M, Pang R, Le Q V. Efficientdet: Scalable and efficient object detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 10781–10790.
- [8] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132–7141.
- [9] Woo S, Park J, Lee J Y, et al. CBAM: Convolutional block attention module[C]//Proceedings of the European conference on computer vision. 2018: 3–19.
- [10] Hou Q, Zhou D, Feng J. Coordinate attention for efficient mobile network design[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 13713–13722.
- [11] Jocher G, Chaurasia A, Qiu J. Ultralytics YOLOv5[J]. GitHub repository, 2020.
- [12] Wang C Y, Bochkovskiy A, Liao H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 7464–7475.

A 完整训练配置

```
# YOLOv11n 基线训练配置
model: yolo11n.pt # COCO pretrained
data: wind_turbine_2cls.yaml
epochs: 150
batch: 8
imgsz: 640
optimizer: auto # AdamW
lr0: 0.001
lrf: 0.0001
cos_lr: True
warmup_epochs: 5
warmup_momentum: 0.8
weight_decay: 0.0005
patience: 30
mosaic: 1.0
mixup: 0.1
copy_paste: 0.1
device: 0
workers: 4
```

B 模型结构详细说明

YOLOv11n 网络结构包含 101 层，主要组件：

- Backbone: Conv + C3k2 + SPPF + C2PSA
- Neck: Upsample + Concat + C3k2 (PANet 结构)
- Head: Detect (3 个检测尺度: P3/P4/P5)
- 参数量: 2.62M, 计算量: 6.3 GFLOPs